

FORWARD PASS

$$s = x + y = 2 + 3 = 5$$

$$p = x \cdot y = 2 \cdot 3 = 6$$

$$f = s \cdot p = 30$$

Reverse Pass

- $f = s \cdot p$
- $p = x \cdot y$

$$\frac{\partial f}{\partial s} = p$$

$$\frac{\partial f}{\partial p} = s$$

$$\frac{\partial s}{\partial x} = 1 + 0 = 1$$

$$\frac{\partial s}{\partial y} = 0 + 1 = 1$$

$$\frac{\partial p}{\partial x} = y$$

$$\frac{\partial p}{\partial y} = x$$

Applico la chain rule

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial s} \cdot \frac{\partial s}{\partial x} + \frac{\partial f}{\partial p} \cdot \frac{\partial p}{\partial x} = p \cdot 1 + s \cdot y = 6 \cdot 1 + 5 \cdot 3 = 21$$

$$\frac{\partial f}{\partial y} = \frac{\partial f}{\partial s} \cdot \frac{\partial s}{\partial y} + \frac{\partial f}{\partial p} \cdot \frac{\partial p}{\partial y} = p \cdot 1 + s \cdot x = 6 \cdot 1 + 5 \cdot 2 = 16$$

Cosa capisco da questo esercizio? Capisco quanto in peso x e y impattano rispetto alla funzione di loss f . Vedo che x ha un impatto maggiore.


ESERCIZIO 3

Consider a 2-Layer function: $z = \tanh(xy + 1)$ $x=1$ e $y=2$

- Build a computation graph:
- Forward pass: compute z .
- Reverse pass: compute gradient $\frac{\partial z}{\partial x}$, $\frac{\partial z}{\partial y}$.

FORWARD:

- $u = x \cdot y = 2$
- $v = u + 1 = 3$
- $z = \tanh(v) = \tanh(3) \approx 0.995$



Reverse Pass

- $z = \tanh(v) \leadsto \frac{\partial z}{\partial v} = \text{sech}^2(v) = 1 - \tanh^2(v) \approx 1 - (0.995)^2 \approx 0.01$

- $v = u + 1 \leadsto \frac{\partial v}{\partial u} = 1$
- $u = x \cdot y \leadsto \frac{\partial u}{\partial x} = y = 2$

$$\frac{\partial u}{\partial y} = x = 1$$

Chain Rule

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial v} \cdot \frac{\partial v}{\partial u} \cdot \frac{\partial u}{\partial x} = 0.01 \cdot 1 \cdot 2 \approx 0.02$$

$$\frac{\partial z}{\partial y} = \frac{\partial z}{\partial v} \cdot \frac{\partial v}{\partial u} \cdot \frac{\partial u}{\partial y} = 0.01 \cdot 1 \cdot 1 \approx 0.01$$

ESERCIZIO 4 given: $g(w) = (w-3)^2$ $w_0 = 0$ $\alpha = 0.1$

$$g'(w) = 2(w-3)$$

$$w^k = w^{k-1} - \alpha \nabla g'(w^{k-1})$$

- ① WRITE the gradient descent Rule
- ② Compute the first 5 iter... $w_1 \dots w_5$
- ③ sketch the cost function values.

$$w_0 = 0$$

$$w_1 = 0,8 \cdot 0 + 0,6 = 0,6$$

$$w_2 = 0,8 \cdot 0,6 + 0,6 = 1,08$$

$$w_3 = 0,8 \cdot 1,08 + 0,6 = 1,464$$

$$w_4 = 0,8 \cdot 1,464 + 0,6 = 1,7712$$

$$w_5 = 0,8 \cdot 1,7712 + 0,6 = 2,01696$$

Ad ogni passo l'iterazione ci spinge un po' più vicino al minimo vero $w^* = 3$. La velocità con cui ci avviciniamo a 3 diminuisce gradualmente.

$$w_{k+1} = w_k - \alpha g'(w_k) =$$

$$w_{k+1} = w_k - 0,2(w_k - 3) =$$

$$w_{k+1} = w_k - 0,2w_k + 0,6$$

$$w_{k+1} = (1 - 0,2)w_k + 0,6$$

$$w_{k+1} = 0,8w_k + 0,6$$

NOTIAMO come solo lo 0,2% del vecchio valore è mantenuto.

Esercizio 5

$$g(w_1, w_2) = w_1^2 + 2w_2^2$$

① Compute the gradient $\nabla g(w)$

② Apply GD from initial point $(w_1, w_2) = (2, 1)$ with learning rate $\alpha = 0,2$

③ Compute the first 3 update explicitly.

for computing the gradient $\nabla g(w_1, w_2)$ we have to apply the first derivative to the function $g(w_1, w_2) \rightsquigarrow g'(w_1, w_2) = 2w_1 + 4w_2$

$$\nabla g(w_1, w_2) = \begin{bmatrix} 2w_1 \\ 4w_2 \end{bmatrix}$$

il gradiente è la derivata della funzione.

Rule for each weight:

$$\boxed{w_1} \quad w_1^{k+1} = w_1^k - \alpha \nabla g(w_1) =$$

$$w_1^{k+1} = w_1^k - 0,2(2w_1^k) =$$

$$w_1^{k+1} = w_1^k - 0,4w_1^k =$$

$$\boxed{w_1^{k+1} = 0,6w_1^k}$$

$$\boxed{w_2} \quad w_2^{k+1} = w_2^k - \alpha \nabla g(w_2) =$$

$$w_2^{k+1} = w_2^k - 0,2(4w_2^k) =$$

$$w_2^{k+1} = w_2^k - 0,8w_2^k =$$

$$\boxed{w_2^{k+1} = 0,2w_2^k}$$

Questo è il modo in cui combaciamo i pesi.

Let's compute the iteration starting with $(2, 1)$

$$k=1 \rightsquigarrow (w_1, w_2) = (0,6 \cdot 2, 0,2 \cdot 1) = (1,2, 0,2)$$

$$k=2 \rightsquigarrow (1,2, 0,2) = (0,72, 0,04)$$

$$k=3 \rightsquigarrow (0,72, 0,04) = (0,432, 0,008)$$

Obiettivo: Vogliamo capire come la funzione di Loss guida e' aggiornare dei pesi per far sì che la nostra Rete produce output sempre più vicini a quelli desiderati.

EX.

Immagina di avere un modello lineare usiamo ad esempio $(x, y) = (2, 5)$

PASSO 1: Inizializzo i PESI

$$\text{Pesi iniziali: } w = 0,5 \quad b = 0,0$$

$$\hat{y} = w \cdot x + b$$

peso Bias

output Predetto

input

! noi non sappiamo nulla quindi impostiamo valori casuali.

PASSO 2: FORWARD PASS (PREDIZIONE)

$$\hat{y} = w \cdot x + b = 0.5 \cdot 2 + 0 = 1 \leftarrow \text{PREDIZIONE}$$


PASSO 3: calcolo delle LOSS (ERRORE). usiamo MSE

$$L = \frac{1}{2}(\hat{y} - y)^2 = \frac{(1 - 5)^2}{2} = \frac{16}{2} = 8 \leftarrow \text{siamo molto lontani dal TARGET.}$$

PASSO 4: Backpropagation (calcolo del Gradiente): come cambiamo i Pesi??

! Deriviamo la Loss rispetto a $\hat{y}$

GRAFO COMPUT:



$$\begin{cases} a = w \cdot x \\ \hat{y} = a + b \\ L = \frac{1}{2}(\hat{y} - y)^2 \end{cases}$$

BACKWARD PASS

$$\frac{\partial L}{\partial \hat{y}} = \hat{y} - y$$

$$\frac{\partial \hat{y}}{\partial a} = 1$$

$$\frac{\partial a}{\partial w} = x$$

$$\frac{\partial \hat{y}}{\partial b} = 1$$

$$[w] \rightarrow \frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial a} \cdot \frac{\partial a}{\partial w} = (\hat{y} - y) \cdot x = (-4) \cdot 2 = -8$$

$$[b] \rightarrow \frac{\partial L}{\partial b} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial b} = (\hat{y} - y) \cdot 1 = -4$$

PASSO 5: GD update dei Pesi.
 $\alpha = 0.1$

Regola di aggiornamento: $w := w - \alpha \frac{\partial L}{\partial w}$

$$b := b - \alpha \frac{\partial L}{\partial b}$$

$$\begin{aligned} w^1 &= 0.5 - 0.1 \cdot (-8) = 1.3 \\ b^1 &= 0 - 0.1 \cdot (-4) = 0.4 \end{aligned} \quad \text{NUOVI PESI } K=1$$

Predict

$$\hat{y} = w^1 x + b^1 = 1.3 \cdot 2 + 0.4 = 3 \quad \text{Nota come la predizione diventa più precisa e vicino al 5 del Dataset.}$$

ovviamente questo Processo viene eseguito su ogni riga del Dataset. Non sulle stesse.